

Curso de Pós-Graduação em Ciências Veterinárias - UFRRJ

Métodos Estatísticos

Prof: Wagner Tassinari

wagner.tassinari@ini.fiocruz.br

Intervalos de Confiança e Testes de Hipótese

Teste para a média populacional

Teste para a média populacional

- Nosso objetivo agora é apresentar procedimentos estatísticos simples para verificar se um conjunto de dados amostrais dá ou não suporte à uma conjectura sobre o valor médio (desconhecido) de uma característica de interesse, observável em “indivíduo” de uma população.
- Mais precisamente, procedimentos para testar hipóteses sobre , tomando como base o valor médio dessa característica, observado em uma amostra casual simples de tamanho n desses “indivíduos”.

Teste para a média populacional () - One *Sample t-test*

- Intervalo de Confiança

$$P[\mu \in (\bar{x} \pm t_{(n-1);\alpha} \times s/\sqrt{n}] = 1 - \alpha$$

- Hipóteses

- $H_0 : \mu = \mu_0$
- $H_1 : \mu \neq \mu_0$
- $H_1 : \mu < \mu_0$
- $H_1 : \mu > \mu_0$

- Estatística Teste

$$t_{calc} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

Exemplo:

Voltando ao exemplo dos pássaros migratórios, bibliografias recentes sobre estes passaros mostram que a massa média destes pássaros no mês de agosto é de $\mu = 14.1$. Verifique se a média dessa amostra coletada corresponde com a massa média verificada na maioria das literaturas sobre o assunto (μ , média populacional).

- $H_0 : \mu = 14.1$
- $H_1 : \mu \neq 14.1$

Solução utilizando o plugin Rcommander.EZT

- Importar o arquivo “massapassaros0.xlsx”
 - Rcommander → Arquivo → Importar arquivos de dados → from Excel data set
- Testar a média
 - Rcommander → Estatísticas → Médias → Teste t para uma amostra





```
Output
> (res <- t.test(banco05Agosto, alternative='two.sided', mu=14.1, conf.level=0.95))

One Sample t-test

data: banco05Agosto
t = -10.286, df = 9, p-value = 0.000002823
alternative hypothesis: true mean is not equal to 14.1
95 percent confidence interval:
 10.89173 12.04827
sample estimates:
mean of x
 11.47

> cat(gettext(domain="R-RcmdrPlugin.EZR", "mean"), " = ", res$estimate, ", ", gettext(domain="R-RcmdrPlugin.EZR", "95% CI"), " ",
+ res$conf.int[1], "- ", res$conf.int[2], ", ", gettext(domain="R-RcmdrPlugin.EZR", "p.value"), " = ", signif(res$p.value, digits=3),
+ "\n", sep="")
mean = 11.47, 95% CI 10.89173-12.04827, p.value = 0.00000282
```

como o p – *valor* < 0.001 , rejeita-se H_0 , ou seja, a massa média dos pássaros desta amostra não corresponde com o a média encontrada na literatura.

Teste para a comparação de duas médias populacionais (μ_1, μ_2) - Grupos Independentes

- Intervalo de confiança

$$P[\mu_1 - \mu_2 \in (\bar{x}_1 - \bar{x}_2 \pm t_{(n_1+n_2-2; \alpha)} \cdot s_p \sqrt{1/n_1 + 1/n_2})] = 1 - \alpha$$

- Sendo s_p o desvio-padrão conjugado

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

- Hipóteses:

- $H_0 : \mu_1 = \mu_2 \therefore \mu_1 - \mu_2 = 0$
- $H_1 : \mu_1 \neq \mu_2 \therefore \mu_1 - \mu_2 \neq 0$

- Estatística de teste

$$t_{calc} = \frac{\bar{x}_1 - \bar{x}_2}{s_p / \sqrt{1/n_1 + 1/n_2}}$$

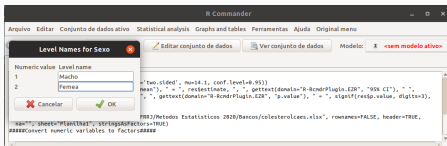

Exemplo:

Comparando as distribuições do teor de colesterol sérico em cães machos e fêmeas normais, medidos em mg/100ml, pergunta-se: É possível responder se existe diferença significativa no teor de de colesterol entre cães machos e fêmeas ?

- $H_0 : \mu_{macho} = \mu_{femea} \therefore \mu_{macho} - \mu_{femea} = 0$
- $H_1 : \mu_{macho} \neq \mu_{femea} \therefore \mu_{macho} - \mu_{femea} \neq 0$

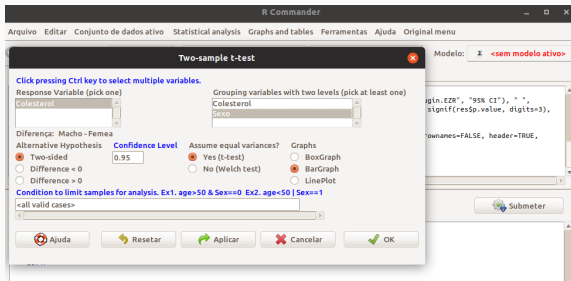
Solução utilizando o plugin Rcommander.EZT

- Importar o arquivo “colesterolcaes.xlsx”
 - Rcommander → Arquivo → Importar arquivos de dados → from Excel data set
- Colocar os *labels* na variável categórica (qualitativa), sexo
- Rcommander → Conjunto de dados ativo → Variables → Convert numeric variables to factors

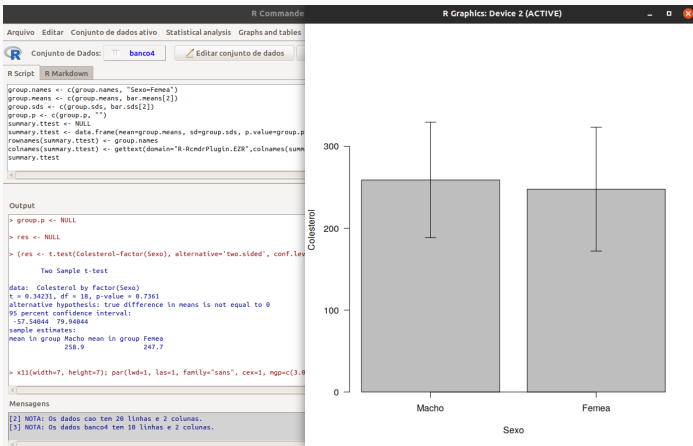


Solução utilizando o plugin Rcommander.EZT

- Testar os dois grupos
 - Rcommander → Statistical analysis → Continuous variables → Two-sample t-test

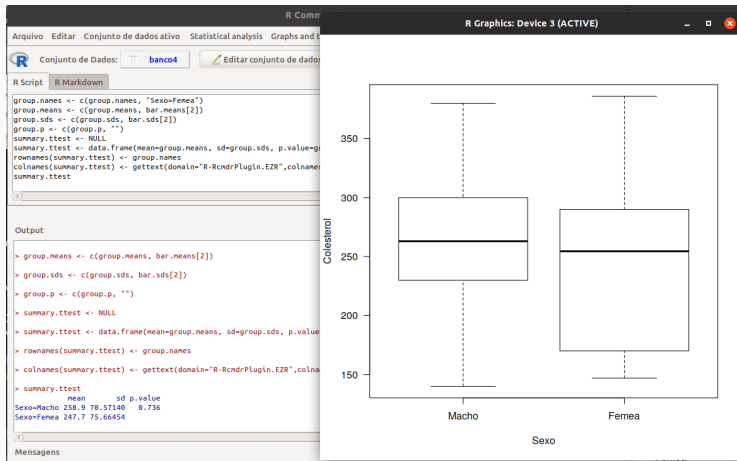


Solução utilizando o plugin Rcommander.EZT



como o $p\text{-valor} = 0,7361$, não rejeita-se H_0 , ou seja, não existe diferença significativa entre o nível dos colesteróis entre cães fêmeas e cães machos.

Solução utilizando o plugin Rcommander.EZR



Teste para a comparação de duas médias populacionais (μ_1 e μ_2) - Dados Pareados

- Intervalo de Confiança

$$P[\mu \in (\bar{d} \pm t_{(n-1;\alpha)} \cdot s_d / \sqrt{n})] = 1 - \alpha$$

- Hipóteses

- $H_0 : \mu_{antes} = \mu_{depois} \therefore \mu_{antes} - \mu_{depois} = 0$
- $H_1 : \mu_{antes} \neq \mu_{depois} \therefore \mu_{antes} - \mu_{depois} \neq 0$

- Estatística Teste

$$t_{calc} = t_d = \frac{\bar{d}}{s_d / \sqrt{n}}$$


Exemplo:

Dez cobaias foram submetidas ao tratamento de engorda com certa ração. Os pesos em gramas, antes e após o teste são dados a seguir (supõe-se que provenham de distribuições normais). A 1% de significância, podemos concluir que o uso da ração contribuiu para o aumento do peso médio dos animais ?

- $H_0 : \mu_{antes} = \mu_{depois} \therefore \mu_{antes} - \mu_{depois} = 0$
- $H_1 : \mu_{antes} \neq \mu_{depois} \therefore \mu_{antes} - \mu_{depois} \neq 0$

Solução utilizando o plugin Rcommander.EZT

- Importar o arquivo “pesocobaias0.xlsx”
 - Rcommander → Arquivo → Importar arquivos de dados → from Excel data set
- Testar os dois grupos
 - Rcommander → Statistical analysis → Continuous variables → Paried t-test



Solução utilizando o plugin Rcommander.EZT

```
> #####Paired t-test#####
> (res <- t.test(dado6$antes, dado6$depois, alternative='two.sided', conf.level=0.99, paired=TRUE))

Paired t-test

data: dado6$antes and dado6$depois
t = -2.9635, df = 9, p-value = 0.01587
alternative hypothesis: true difference in means is not equal to 0
99 percent confidence interval:
 -13.8377274  0.6377274
sample estimates:
mean of the differences
      -6.6

> mean1 <- mean(dado6$antes, na.rm=TRUE)
> mean2 <- mean(dado6$depois, na.rm=TRUE)
> sd1 <- sd(dado6$antes, na.rm=TRUE)
> sd2 <- sd(dado6$depois, na.rm=TRUE)

> sd1 <- sd(dado6$antes, na.rm=TRUE)
> sd2 <- sd(dado6$depois, na.rm=TRUE)
> summary.ttest <- NULL
> summary.ttest <- data.frame(mean=c(mean1, mean2), sd=c(sd1, sd2), p.value=c(signif(res$p.value, digit=3), ""))
> rownames(summary.ttest) <- c("antes", "depois")
> colnames(summary.ttest) <- gettext(domain="R-RcmdrPlugin.EZR", colnames(summary.ttest))

> summary.ttest
      mean      sd p.value
antes 648.4 58.85236 0.0159
depois 655.0 59.20023

<|
Mensagens
[10] NOTA: Os dados banco4 tem 10 linhas e 2 colunas.
```

Como $p - \text{valor} = 0,0158$, rejeita-se H_0 , ou seja, existe diferença significativa entre as médias do antes e do depois.

Teste para a comparação para mais de duas médias populacionais - ANOVA

- Hipóteses:
 - $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$
 - $H_1 : \mu_i \neq \mu_j$, sendo $i \neq j$
- Estatística Teste: Teste F

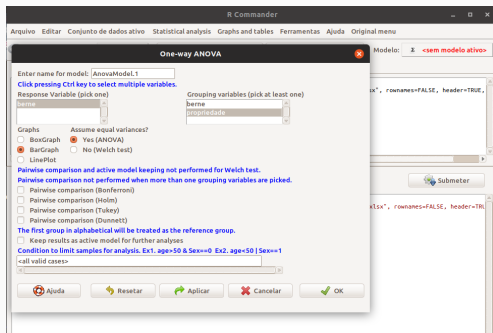
Exemplo:

Gostaríamos de verificar se o número de bernes por animal é a mesma nas três propriedades distintas. Para cada propriedade foram selecionados 5 animais.

- $H_0 : \mu_a = \mu_b = \mu_c$
- $H_1 : \mu_i \neq \mu_j$, sendo $i \neq j$

Solução utilizando o plugin Rcommander.EZT

- Importar o arquivo “bernepropriedades.xlsx”
 - Rcommander → Arquivo → Importar arquivos de dados → from Excel data set
 - Testar os grupos
 - Rcommander → Statistical analysis → Continuous variables → one-Way ANOVA



Solução utilizando o plugin Rcommander.EZT

```
group.means <- c(group.means, bar.means[2])
group.sds <- c(group.sds, bar.sds[2])
group.p <- c(group.p, "")
group.names <- c(group.names, "propriedade=C")
group.means <- c(group.means, bar.means[3])
group.sds <- c(group.sds, bar.sds[3])
group.p <- c(group.p, "")
summary(AnovaModel.1)
summary.anova <- NULL
summary.anova <- data.frame(mean=group.means, sd=group.sds, p.value=group.p)


Output

> group.sds <- c(group.sds, bar.sds[3])
> group.p <- c(group.p, "")
> summary(AnovaModel.1)
      Df Sum Sq Mean Sq F value Pr(>F)
factor(propriedade) 2    2661   1330.5      7.6 0.00737 **
Residuals          12    2101    175.1
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary.anova <- NULL
> summary.anova <- data.frame(mean=group.means, sd=group.sds, p.value=group.p)
> rownames(summary.anova) <- group.names
> colnames(summary.anova) <- gettext(domain="R-RcmdrPlugin.EZT",colnames(summary.anova))
> summary.anova
      mean      sd p.value
propriedade=A 45.4 14.690133 0.00737
propriedade=B 12.8  3.420526
propriedade=C 30.2 17.253985

Mensagens

[1] NOTA: Versão do R Commander 2.6-1: Sat Jan 18 08:30:21 2020
[2] NOTA: Os dados banco tem 15 linhas e 2 colunas.
```



- Como $p - \text{valor} = 0,00104$, rejeita-se H_0
- Verificamos que existe diferença significativa entre as médias.

Testes para a variância

Teste para a comparação de duas variâncias populacionais

- Hipóteses

- $H_0 : \sigma_1^2 = \sigma_2^2 (= \sigma) \text{ ou } \frac{\sigma_1^2}{\sigma_2^2} = 1$

- $H_1 : \sigma_1^2 \neq \sigma_2^2 \text{ ou } \frac{\sigma_1^2}{\sigma_2^2} \neq 1$


- Estatística do teste

- $F_{calc} = \frac{s_1^2}{s_2^2}$

- A utilização deste teste é necessária quando precisamos comparar diferenças entre médias. Alguns softwares já fazem isso, como é o caso do Bioestat.

Solução utilizando o plugin Rcommander.EZT

- Importar o arquivo “pesocobaias.xlsx”
 - Rcommander → Arquivo → Importar arquivos de dados → from Excel data set
- Testar a variância dos dois períodos
 - Rcommander → Statistical analysis → Continuous variables → Two-variances F-test



Solução utilizando o plugin Rcommander.EZT

```
Output
> #####Two-variances F-test#####
> tapply(banco3$peso, banco3$periodo, var, na.rm=TRUE)
      1      2
3463.600 3504.667
> res <- NULL
> (res <- var.test(peso ~ periodo, alternative='two.sided', conf.level=0.95, data=banco3))

      F test to compare two variances

data: peso by periodo
F = 0.98828, num df = 9, denom df = 9, p-value = 0.9863
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.2454753 3.9788187
sample estimates:
ratio of variances
 0.9882823

> cat(gettext(domain="R-RcmdrPlugin.EZR", "F test"), " ", gettext(domain="R-RcmdrPlugin.EZR", "p.value"), " = ",
+   signif(res$p.value, digits=3), "
+   ", sep="")
F test p.value = 0.986
```

- Como $p\text{-valor} = 0.986$, não rejeita-se H_0
- Verificamos que as variâncias entre os períodos são homogêneas (iguais).

Teste para a comparação de duas ou mais variâncias populacionais - Bartlett's Test

- Hipóteses

- $H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2 = \sigma^2$
- $H_1 : \sigma_i^2 \neq \sigma_j^2$, sendo $i \neq j$

- Estatística de teste


$$T = \frac{(n - k) \ln(s_p^2) - \sum_{i=1}^k (n_i - 1) \ln(s_i^2)}{1 + (1/(3(k - 1)))((\sum_{i=1}^k 1/(n_i - 1)) - 1/(n - k))}$$

- sendo $n = n_1 + n_2 + \dots + n_k$, k o número de grupos ou amostras e a variância conjunta sendo:

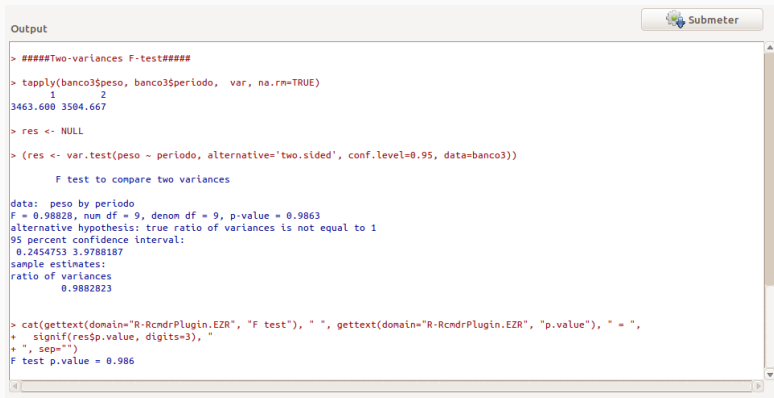
$$s_p^2 = \frac{\sum_{i=1}^k (n_i - 1)(s_i^2)}{n - k}$$

Solução utilizando o plugin Rcommander.EZT

- Importar o arquivo “bernepropriedades.xlsx”
 - Rcommander → Arquivo → Importar arquivos de dados → from Excel data set
 - Comparar as variâncias do número de berne entre as propriedades
 - Rcommander → Statistical analysis → Continuous variables → Bartlett's test



Solução utilizando o plugin Rcommander.EZT



The screenshot shows the R Commander EZT interface. At the top right is a 'Submiter' button with a globe icon. The main area is titled 'Output' and contains the following text:

```
> #####Two-variances F-test#####  
> tapply(banco3$peso, banco3$periodo, var, na.rm=TRUE)  
      1      2  
3463.600 3504.667  
  
> res <- NULL  
  
> (res <- var.test(peso ~ periodo, alternative='two.sided', conf.level=0.95, data=banco3))  
  
      F test to compare two variances  
  
data:  peso by periodo  
F = 0.98828, num df = 9, denom df = 9, p-value = 0.9863  
alternative hypothesis: true ratio of variances is not equal to 1  
95 percent confidence interval:  
 0.2454753 3.9788187  
sample estimates:  
ratio of variances  
 0.9882823  
  
> cat(gettext(domain="R-RcmdrPlugin.EZR", "F test"), " ", gettext(domain="R-RcmdrPlugin.EZR", "p.value"), " = ",  
+   signif(res$p.value, digits=3), "  
+   ", sep="")  
F test p.value = 0.986
```

- Como $p - \text{valor} = 0,02908$, rejeita-se H_0
- Verificamos que a variabilidade do número de bernes entre entre as propriedades é heterogênea.

Teste para proporções

Teste para Proporção Populacional (π)

- Intervalo de Confiança

$$P[\pi \in (p \pm z_{\alpha/2} \cdot \sqrt{\frac{p(1-p)}{n}})] = 1 - \alpha$$

- Hipóteses

- $H_0 : \pi = \pi_0$
- $H_1 : \pi \neq \pi_0$
- $H_1 : \pi < \pi_0$
- $H_1 : \pi > \pi_0$

- Estatística Teste

$$z_{calc} = \frac{p - \pi_0}{\sqrt{\frac{p(1-p)}{n}}}$$

Exemplo:

Amostras de sangue de 115 cabeças de gado foram analisadas através de um teste sorológico para *Leptospira sp.* e, de acordo com o título, cada amostra foi classificada como positiva ou negativa. Na amostra, 36 animais apresentaram título positivo. Deseja-se saber se a prevalência de animais infectados foi de 40% em todo estabelecimento.

- $H_0 : \pi = 40\%$
- $H_1 : \pi \neq 40\%$

Solução utilizando o plugin Rcommander.EZT

- Não existe a necessidade de abrir um banco de dados (tabela)
- Estimando o intervalo de confiança para a proporção
 - Rcommander → Statistical analysis → Discrete variables → Confidence interval for a proportion



Solução utilizando o plugin Rcommander.EZT



The screenshot shows the R Commander application window. The menu bar includes 'Arquivo', 'Editar', 'Conjunto de dados ativo', 'Statistical analysis', 'Graphs and tables', 'Ferramentas', 'Ajuda', and 'Original menu'. The 'Conjunto de Dados' field shows '<Não há conjunto de dados ativo>'. The 'R Script' tab is active, displaying the following R code:

```
#####Confidence interval for a proportion#####  
prop.conf(36, 115, 95)
```

The 'Output' window shows the result of the command:

```
> #####Confidence interval for a proportion#####  
> prop.conf(36, 115, 95)  
[1] Probability : 0.313  
[1] 95% confidence interval : 0.23 - 0.406
```

- Como o valor 40% está incluído dentro do intervalo de confiança, podemos dizer que não rejeitamos H_0 , ou seja, a prevalência de animais infectados pode ser considerada de 40% em todo estabelecimento.

Solução utilizando a linha de comando do R

```
prop.test(36, 115, 0.4)
```

1-sample proportions test with continuity correction

data: 36 out of 115, null probability 0.4

X-squared = 3.2699, df = 1, p-value = 0.07056

alternative hypothesis: true p is not equal to 0.4

95 percent confidence interval:

0.2315949 0.4071869

sample estimates:

p

0.3130435

- Como o $p\text{-valor} = 0,071$, não rejeitamos H_0 .

Teste para a Comparação de duas Proporções Populacionais (π_1 e π_2)

- Intervalo de Confiança

$$P[\pi_1 - \pi_2 \in (p_1 - p_2 \pm z_{\alpha/2} \cdot \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}})] = 1 - \alpha$$

- Hipóteses

- $H_0 : \pi_1 = \pi_2$
- $H_1 : \pi_1 \neq \pi_2$

- Estatística Teste

$$z_{calc} = \frac{p_1 - p_2}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}}$$


Exemplo:

Pesquisadores decidiram avaliar se a proporção de cães machos é idêntica em cães domiciliados e não-domiciliados. Fizeram um levantamento em uma determinada cidade, e observaram que, dos 510 cães domiciliados amostrados, 301 eram machos e, dentre os 230 não-domiciliados, 97 eram machos. Pergunta-se, existe diferença significativa entre as duas proporções ?

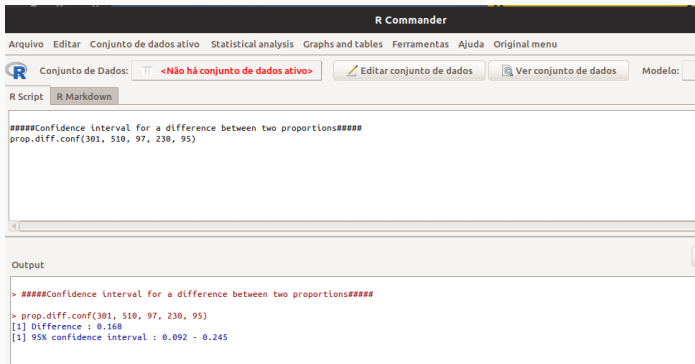
- $H_0 : \pi_1 = \pi_2$
- $H_1 : \pi_1 \neq \pi_2$

Solução utilizando o plugin Rcommander.EZT

- Não existe a necessidade de abrir um banco de dados (tabela)
- Estimando o intervalo de confiança para a proporção
 - Rcommander → Statistical analysis → Discrete variables → Confidence interval for a difference between two proportions



Solução utilizando o plugin Rcommander.EZT



The screenshot shows the R Commander application window. The menu bar includes 'Arquivo', 'Editar', 'Conjunto de dados ativo', 'Statistical analysis', 'Graphs and tables', 'Ferramentas', 'Ajuda', and 'Original menu'. The 'Conjunto de Dados' (Data Set) section shows '<Não há conjunto de dados ativo>' (No active data set). The 'R Script' tab is active, displaying the following code:

```
#####Confidence interval for a difference between two proportions#####  
prop.diff.conf(301, 510, 97, 230, 95)
```

The 'Output' window shows the result of the command:

```
> #####Confidence interval for a difference between two proportions#####  
> prop.diff.conf(301, 510, 97, 230, 95)  
[1] Difference : 0.168  
[1] 95% confidence interval : 0.092 - 0.245
```

- Como o 0 (zero) não está incluído dentro do intervalo de confiança, podemos dizer que existe diferença significativa entre as proporções.

Solução utilizando a linha de comando do R

```
prop.test(c(301,97), c(510,230))
```

2-sample test for equality of proportions with continuity

data: c(301, 97) out of c(510, 230)

X-squared = 17.425, df = 1, p-value = 2.988e-05

alternative hypothesis: two.sided

95 percent confidence interval:

0.08852378 0.24839011

sample estimates:

prop 1 prop 2

0.5901961 0.4217391

- Como o p – valor $< 0,05$, rejeitamos H_0 .